Agente conversacional multimodal para quejas urbanas: clasificación temática, sentimiento y embeddings

Procesamiento del Lenguaje Natural (PLN)

Autora: Salma Ghailan Serroukh

Índice

1. Introducción y objetivos **2**

2. Datos y preprocesamiento **2**

3. Modelado **3**

3.1. Clasificación temática 3

3.1.1. Modelado temático mediante TF–IDF y NMF 4

3.1.2. Modelado temático mediante BoW y LDA 5

3.1.3. Validación cualitativa mediante similitud semántica con Word2Vec 6

3.2. Análisis de sentimiento 7

3.3. Descripción de imágenes 8

3.4. Integración conversacional (LLM y demo) 9

3.4.1. Arquitectura del agente conversacional 9

3.4.2. Demo interactiva 9

4. Conclusiones **10**

5. Reproducibilidad **11**

1. Introducción y objetivos

Las quejas urbanas presentan alta variabilidad léxica y, en muchos casos, información multimodal, lo que dificulta su procesamiento automático. La identificación de la categoría del incidente y su nivel de urgencia resulta fundamental para la priorización de actuaciones.

Este proyecto desarrolla un agente conversacional multimodal para el análisis automático de quejas urbanas en texto e imagen, orientado a la clasificación temática, estimación de urgencia y generación de respuestas contextuales.

Los objetivos específicos son:

- Aplicar técnicas de preprocesamiento y representación vectorial del texto.
- Evaluar modelos de clasificación temática y análisis de sentimiento en español.
- Integrar los resultados en un agente conversacional basado en LLM.

La Figura 1 muestra la arquitectura general del sistema.

Figura 1: Pipeline multimodal donde el texto se codifica mediante embeddings para clasificación y análisis de sentimiento, las imágenes se transforman en descripciones textuales, y la información integrada se utiliza como contexto para un agente LLM.

2. Datos y preprocesamiento

Para el desarrollo del sistema se utilizó un conjunto de datos procedente del Portal de Datos Abiertos del Ayuntamiento de Madrid, correspondiente a la plataforma de participación ciudadana. La fuente recoge propuestas y quejas relacionadas con la gestión urbana y los servicios públicos, constituyendo un corpus representativo de lenguaje ciudadano para tareas de clasificación temática.

El dataset se distribuye en formato CSV e incluye 33 671 registros con múltiples variables textuales y

metadatos asociados. Para el análisis se construyó un documento textual por registro a partir de los campos de contenido más informativos, descartando aquellos que introducían ruido semántico en el modelado.

Dado que el conjunto de datos no dispone de anotación temática explícita y presenta una elevada heterogeneidad léxica y estructural, se adoptó un enfoque no supervisado para el análisis del contenido. Asimismo, estas características del lenguaje generado por usuarios motivaron la aplicación de un pipeline de preprocesamiento lingüístico previo al modelado, cuyas principales etapas se ilustran mediante un documento del corpus y se resumen en las Tablas 1 y 2.

```
Estamos hartos de la basura. <p>Buenos días.</p><p>A ver si hay más cubos de basura.
Madrid está sucia.</p>
```

$\Downarrow$

Etapa	Descripción
Limpieza	Eliminación de etiquetas HTML, URLs, correos, menciones, hashtags, emojis y caracteres repetidos, así como normalización de espacios.
Normalización	Conversión a minúsculas, expansión de contracciones (“al”, “del”), normalización de diacríticos preservando *ñ*, eliminación de signos de puntuación, filtrado léxico por frecuencia en español (Zipf) con listas blanca/negra y descarte de documentos con baja proporción de vocabulario válido o longitud insuficiente.

Cuadro 1: Etapas de limpieza y normalización superficial del texto.

```
estamos hartos de la basura a ver si hay mas cubos de basura madrid esta sucia
```

$\Downarrow$

Etapa	Descripción
Tokenización	Segmentación mediante `es_core_news_sm`; selección de tokens alfabéticos.
Lematización	Sustitución por lema canónico; normalización adicional preservando *ñ*.
Stopwords	Eliminación combinada de stopwords estándar de spaCy y listas personalizadas (sociales, dominio local y metadatos).
Filtrado de calidad	Descartado de tokens por longitud mínima y ausencia de vocal, eliminando artefactos léxicos.

Cuadro 2: Preprocesamiento lingüístico aplicado tras la limpieza superficial.

```
harto basura cubo basura sucio
```

3. Modelado

3.1. Clasificación temática

El modelado temático del corpus se abordó mediante un enfoque no supervisado, evaluando distintas representaciones vectoriales y modelos de descomposición con el objetivo de maximizar la separabilidad te-

mática y la interpretabilidad de los resultados. En particular, se analizan dos configuraciones representativas por su buen rendimiento empírico en el dominio urbano:

3.1.1. Modelado temático mediante TF–IDF y NMF

La configuración principal emplea una representación TF–IDF con filtrado de términos muy frecuentes y muy raros, incorporación de n-gramas y normalización, con el objetivo de obtener una representación discriminativa y robusta frente al ruido léxico. La inclusión de bigramas permite capturar expresiones propias del dominio (p. ej., *transporte público*), mientras que el escalado sublineal mitiga el efecto de documentos extensos.

Sobre esta representación se aplica NMF, que factoriza la matriz TF–IDF en una matriz documento–tópico ($\mathbf{W}$) y una matriz tópico–término ($\mathbf{H}$), ambas no negativas. Esta descomposición aditiva favorece la interpretabilidad de los componentes y permite asignar categorías temáticas. El número de tópicos se seleccionó empíricamente, fijándose $k = 15$ como compromiso entre coherencia semántica y granularidad funcional.

Para facilitar la interpretación, los tópicos se rotularon mediante un procedimiento semiautomático con participación humana (*human-in-the-loop*), basado en perfiles léxicos definidos manualmente y comparados con las palabras de mayor peso en $\mathbf{H}$. La proyección t-SNE de la matriz documento–tópico $\mathbf{W}$ (Figura 2) evidencia una separación razonable entre grupos temáticos. Como síntesis cuantitativa, la Tabla 3 recoge las categorías con mayor presencia. Adicionalmente, se generó una versión interactiva de la visualización t-SNE disponible en el notebook `clasificacion_tematica.ipynb`.

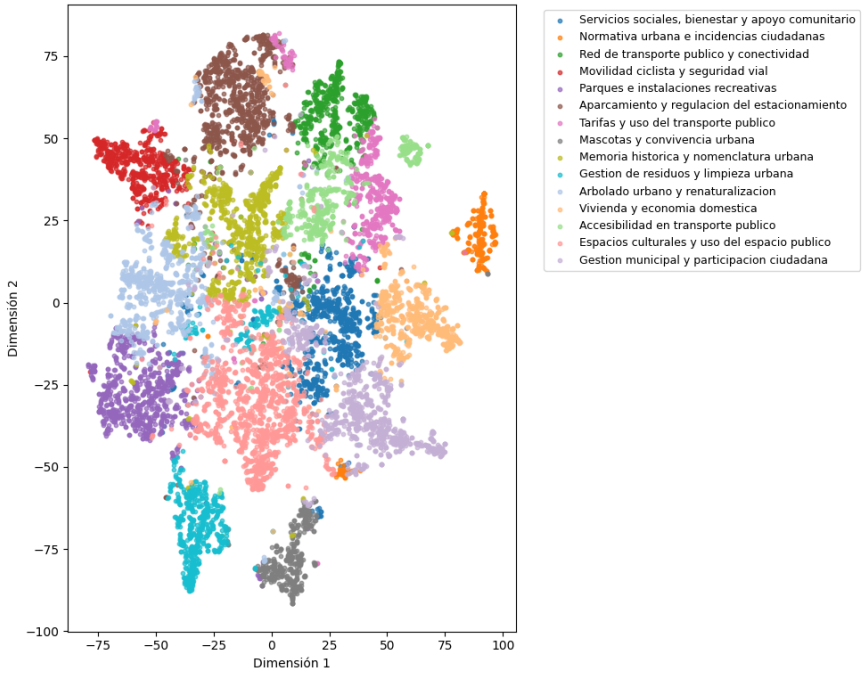

Figura 2: Proyección t-SNE de documentos a partir de la matriz documento–tópico $\mathbf{W}$ del modelo NMF. Cada punto representa una propuesta y el color indica el tópico dominante asignado por el modelo.

Categoría temática (NMF)	N° de documentos
Espacios culturales y uso del espacio público	1248
Aparcamiento y regulación del estacionamiento	946
Gestión municipal y participación ciudadana	864

Cuadro 3: Principales áreas temáticas identificadas en la muestra analizada mediante NMF.

3.1.2. Modelado temático mediante BoW y LDA

Se evaluó un modelo generativo basado en Bag of Words (BoW) y *Latent Dirichlet Allocation* (LDA), con el objetivo de contrastar el espacio temático obtenido con NMF desde un enfoque probabilístico e igualmente interpretable. La representación BoW preserva la frecuencia explícita de los términos, lo que facilita la inspección directa de los tópicos, mientras que LDA modela cada documento como una mezcla de distribuciones latentes. El número de tópicos se fijó en $k = 20$, buscando esta vez una mayor desagregación de subproblemáticas urbanas y una comparación directa con la estructura temática inducida por NMF. La rotulación de los temas se realizó con participación humana, asignando etiquetas a partir de las palabras más probables de cada componente, de forma bastante análoga al procedimiento seguido en el modelo anterior.

La proyección t-SNE de la matriz documento–tópico (Figura 3) muestra agrupaciones coherentes para varios dominios urbanos, aunque con mayor solapamiento entre categorías transversales, especialmente en documentos con baja dominancia temática.

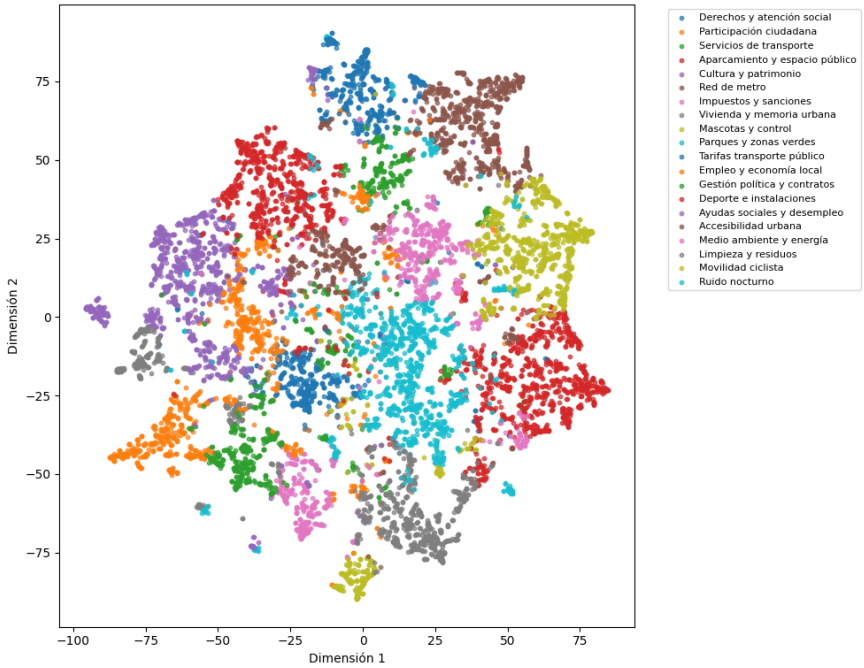

Figura 3: Proyección t-SNE de documentos a partir de la matriz documento–tópico del modelo LDA sobre representación BoW. Cada punto representa una propuesta y el color indica el tópico con mayor probabilidad posterior de pertenencia.

Dado el carácter probabilístico de LDA, cada asignación incorpora una medida explícita de confianza. Al imponer umbrales de pertenencia sobre la probabilidad del tópico dominante, se observa un aumento progresivo de la pureza temática de los clústeres: con umbral $\geq 0{,}6$ las agrupaciones resultan más compactas, y con $\geq 0{,}8$ se obtienen núcleos altamente coherentes, aunque con una reducción notable de cobertura. Este comportamiento se ilustra en la Figura 4:

Figura 4: Proyección t-SNE de subconjuntos de documentos según tópicos LDA bajo distintos umbrales de pertenencia al tópico dominante. Se muestra un ejemplo de documento identificado mediante su título.

3.1.3. Validación cualitativa mediante similitud semántica con Word2Vec

Como verificación adicional de la coherencia temática, se incorporó un módulo de recuperación semántica basado en representaciones distribucionales *Word2Vec* y en el cálculo de similitud coseno entre documentos. Este componente permite evaluar si propuestas cercanas en el espacio semántico comparten, además, categorías temáticas consistentes según los modelos NMF y LDA.

Cada propuesta se representa como el promedio de los vectores de sus palabras, y sobre dichos word embeddings se construye un índice de vecinos más cercanos utilizando similitud coseno. De este modo, es posible recuperar propuestas conceptualmente próximas incluso cuando no comparten exactamente el mismo vocabulario superficial, capturando relaciones semánticas de mayor nivel.

La interfaz interactiva desarrollada permite tanto analizar documentos existentes como introducir un texto nuevo no perteneciente al corpus y obtener simultáneamente: (i) la predicción temática mediante NMF y LDA y (ii) los documentos más similares del conjunto de datos según Word2Vec. Este diseño facilita contrastar la coherencia entre la clasificación temática y la proximidad semántica en un espacio de representación completamente independiente del modelado por tópicos.

En la Figura 5 se muestra un ejemplo de consulta con un texto nuevo relacionado con problemas de limpieza urbana. El sistema asigna coherentemente la categoría de limpieza y residuos en ambos modelos y recupera propuestas del corpus con contenidos análogos, como recogida de basura, contenedores y limpieza de calles. Este comportamiento sugiere que la estructura temática aprendida por los modelos se alinea con la organización semántica capturada por los embeddings distribucionales.

```
Texto procesado:
harto basura cubo basura sucio

[NMF]
Tema predicho: 9
Nombre del tema: Gestion de residuos y limpieza urbana
Confianza (peso máx): 0.163

[LDA]
Tema predicho: 17
Nombre del tema: Limpieza y residuos
Confianza (prob máx): 0.762

[NMF] (pred)
Tema: 9 | Gestion de residuos y limpieza urbana | conf: 0.163
Top-3: [(9, 0.1628724845767778, 'Gestion de residuos y limpieza urbana'), (13, 0.0, 'Espacios culturales y uso del espacio publ

[LDA] (pred)
Tema: 17 | Limpieza y residuos | conf: 0.762
Top-3: [(17, 0.7624989885937927, 'Limpieza y residuos'), (12, 0.012500458144685337, 'Gestión política y contratos'), (8, 0.0125

TOP-10 SIMILARES (Word2Vec + coseno):
```

	doc_index	cosine_sim	tema_nombre_nmf	tema_lda_nombre	title
0	1650	0.869801	Gestion de residuos y limpieza urbana	Limpieza y residuos	Limpieza de las calles
1	8775	0.867387	Gestion de residuos y limpieza urbana	Limpieza y residuos	No dejar. Suciedad. Fuera. De. Los contenedore...
2	549	0.863215	Gestion de residuos y limpieza urbana	Limpieza y residuos	contenedores como los que hay para la ropa par...
3	2045	0.862352	Gestion de residuos y limpieza urbana	Limpieza y residuos	Soterramiento de contenedores de basura
4	2644	0.856009	Gestion de residuos y limpieza urbana	Limpieza y residuos	Contenedores de basura grandes en calles de ba...
5	858	0.853870	Gestion de residuos y limpieza urbana	Limpieza y residuos	Papeleras de colores para reciclaje
6	2478	0.846311	Gestion de residuos y limpieza urbana	Limpieza y residuos	Cubos de basura 24h
7	181	0.839872	Gestion de residuos y limpieza urbana	Limpieza y residuos	Cambiar a contenedores semisoterrados Molok!
8	178	0.835365	Gestion de residuos y limpieza urbana	Limpieza y residuos	Reforma de la recogida de basuras

Figura 5: Ejemplo de consulta con texto nuevo en la interfaz de similitud semántica. Se muestran las categorías asignadas por NMF y LDA junto con los documentos más similares del corpus según Word2Vec y similitud coseno.

Este módulo se emplea como herramienta de validación cualitativa y de apoyo a la interpretabilidad, proporcionando evidencia adicional de que los tópicos identificados reflejan agrupaciones semánticamente consistentes y con capacidad de generalización a nuevas entradas.

3.2. Análisis de sentimiento

Con el fin de enriquecer la clasificación temática con una señal emocional útil para la priorización de incidencias y la generación de respuestas empáticas por parte del agente conversacional, se incorpora un módulo de análisis de sentimiento aplicado a las quejas ciudadanas.

Dado que el corpus municipal no dispone de anotaciones supervisadas de polaridad, se adopta un enfoque de *transfer learning*, empleando un modelo BETO (*BERT* entrenado en español) previamente *fine-tuned* para tareas de análisis de sentimiento. Este enfoque permite obtener estimaciones fiables sin necesidad de construir un conjunto de entrenamiento específico para el dominio. A diferencia de representaciones distribucionales estáticas, el modelo genera embeddings contextuales, donde el significado de las palabras depende del contexto de aparición, lo que resulta especialmente relevante en textos de queja con expresiones implícitas de malestar.

El modelo produce, para cada texto, una distribución de probabilidad sobre las clases `NEG`, `NEU` y `POS`. Además de la etiqueta final, se utiliza la probabilidad asociada a la clase negativa como un indicador continuo de intensidad de malestar, que se discretiza en cuatro niveles (*neutro*, *ligeramente negativo*, *negativo* y *muy negativo*) con el objetivo de aportar una variable interpretable e integrable en los módulos posteriores de priorización y generación de respuestas del agente.

El cruce entre temática y polaridad (Figura 6) muestra un predominio global de mensajes `NEU`, coherente con el carácter informativo del canal. No obstante, se observan diferencias sistemáticas por dominio: temáticas asociadas a fricción cotidiana (p. ej., limpieza, ruido nocturno, aparcamiento o transporte) concentran una mayor proporción de `NEG`, mientras que ámbitos como parques y zonas verdes, cultura o instalaciones deportivas presentan una mayor presencia relativa de `POS`.

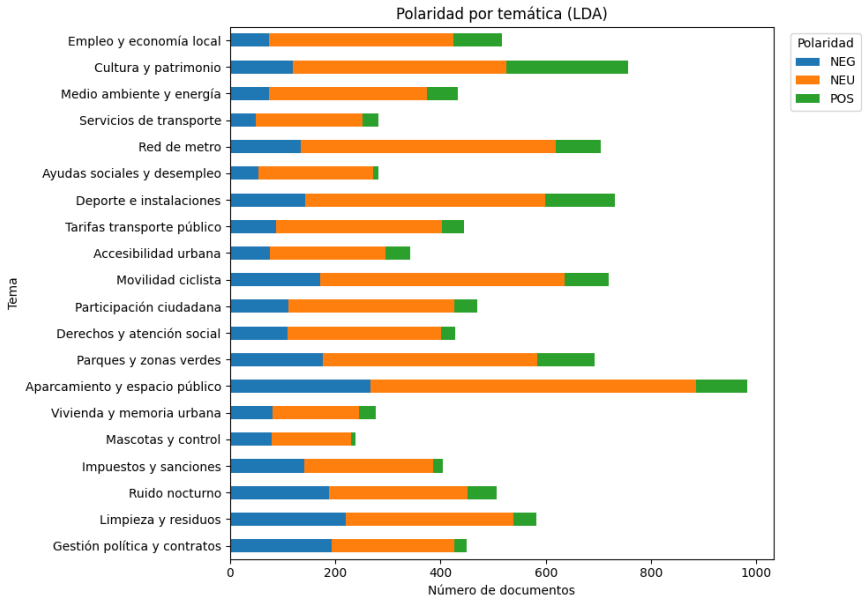

Figura 6: Distribución de polaridad (BETO) por categoría temática.

De forma complementaria, se implementó también un clasificador supervisado clásico basado en Naive Bayes con fines metodológicos y de comparación, permitiendo contrastar empíricamente el rendimiento de enfoques basados en frecuencia de términos frente a modelos contextuales basados en Transformers.

3.3. Descripción de imágenes

De forma complementaria y fuera del alcance principal del trabajo, se incorporó un módulo experimental de descripción automática de imágenes (*image captioning*) basado en un modelo preentrenado de visión–lenguaje (BLIP), con el fin de explorar la integración de información visual en incidencias urbanas.

Cuando se proporciona una imagen, el modelo genera una descripción textual que se incorpora al contexto de entrada del agente, permitiendo enriquecer la interpretación de la incidencia. En ausencia de imagen, el sistema opera exclusivamente con los módulos textuales sin alterar el funcionamiento del pipeline.

3.4. Integración conversacional (LLM y demo)

3.4.1. Arquitectura del agente conversacional

Una vez extraída la información estructurada de cada incidencia (temática, distribución de tópicos, nivel de malestar y, opcionalmente, evidencia visual), se incorpora un componente conversacional basado en un modelo de lenguaje de gran tamaño(LLM) con el objetivo de transformar estas señales analíticas en una respuesta orientada a la gestión efectiva de la incidencia desde la perspectiva del ciudadano.

El LLM actúa como un orquestador que utiliza, explícitamente, las salidas de los módulos previos como contexto de decisión. En este sentido, el agente es capaz de: (i) adaptar el tono de la respuesta en función de la intensidad emocional estimada, (ii) detectar la ausencia de información clave —como la ubicación exacta— y solicitarla explícitamente, y (iii) proponer un nivel de prioridad orientativo para la gestión interna de la incidencia.

La entrada al LLM se construye como una estructura JSON que integra el texto original del usuario, la clasificación temática obtenida mediante NMF y LDA, las variables de sentimiento estimadas con BETO (incluyendo un nivel discretizado de negatividad) y, cuando existe imagen, una descripción textual generada automáticamente mediante BLIP. A partir de este contexto, el modelo produce una salida igualmente estructurada que contiene el estado de la incidencia, la respuesta al ciudadano, la prioridad sugerida y los datos faltantes necesarios para su correcta tramitación.

Este diseño desacopla el análisis automático de la generación de respuestas, favoreciendo una arquitectura modular, interpretable y fácilmente extensible, coherente con escenarios reales de despliegue en los que modelos especializados alimentan a un agente responsable de la interacción final y de decisiones operativas de primer nivel.

3.4.2. Demo interactiva

Como cierre, se implementó una demo interactiva del agente urbano mediante una interfaz ligera desarrollada con Streamlit, que permite simular el uso del sistema por parte de un ciudadano mediante texto y, opcionalmente, imagen. El sistema ejecuta de forma automática la secuencia completa de análisis descrita en secciones anteriores y genera una respuesta empática orientada a la resolución de la incidencia, indicando prioridad y solicitando información adicional cuando es necesario.

Las Figuras 7 y 8 muestran un ejemplo completo de interacción, incluyendo la entrada del ciudadano, la respuesta conversacional del agente y parte del JSON intermedio/final utilizado.

(a) Interfaz de demo: entrada textual y carga opcional de imagen.

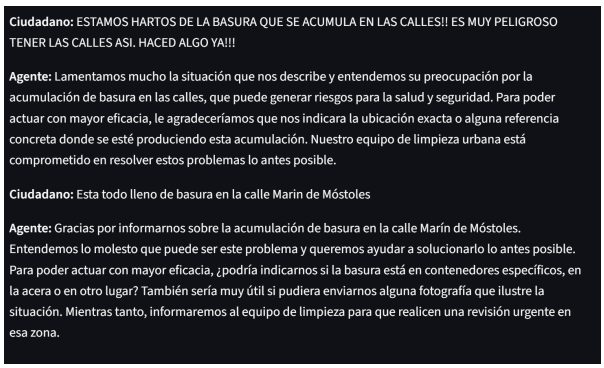

(b) Salida conversacional del agente: respuesta empática y orientada a la resolución.

Figura 7: Demostración del agente urbano mediante interfaz interactiva (Streamlit).

(a) Contexto estructurado: sentimiento (BETO) y descripción visual opcional (BLIP).

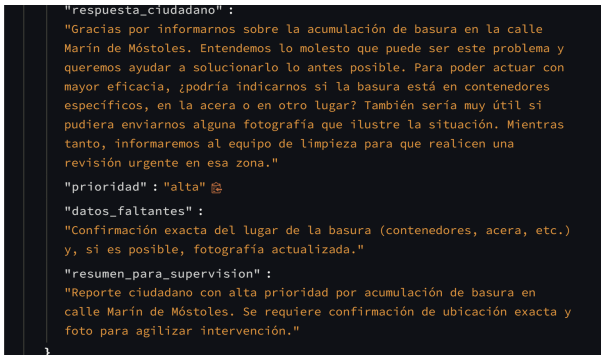

(b) Salida del LLM en formato JSON: estado, prioridad y datos faltantes.

Figura 8: Trazabilidad del proceso: evidencia analítica y decisión conversacional final del agente.

4. Conclusiones

Este trabajo ha supuesto una oportunidad para explorar de forma práctica cómo distintas técnicas de Procesamiento del Lenguaje Natural pueden integrarse en un sistema coherente orientado a un problema real y socialmente relevante. Más allá de la aplicación individual de modelos, el principal aprendizaje ha sido comprender cómo diseñar un pipeline completo, donde cada componente aporta una señal distinta pero complementaria para apoyar la toma de decisiones.

A lo largo del desarrollo se ha puesto de manifiesto la importancia de la interpretabilidad en contextos reales. Los modelos de tópicos no solo permiten agrupar documentos, sino que ayudan a entender qué preocupa a la ciudadanía y cómo se organizan esas preocupaciones en grandes áreas temáticas. La incorporación de Word2Vec como espacio semántico independiente, junto con una interfaz de exploración, ha permitido contrastar cualitativamente estas agrupaciones y comprobar que la coherencia temática no debe evaluarse desde un único modelo, sino desde varias perspectivas complementarias.

De forma similar, el análisis de sentimiento con BETO ha mostrado que la información emocional añade

una dimensión clave al análisis puramente temático. En el contexto de quejas ciudadanas, la intensidad del malestar resulta especialmente relevante para priorizar incidencias.

La integración final mediante un agente basado en modelos de lenguaje de gran escala representa un paso hacia arquitecturas más cercanas a escenarios reales de atención ciudadana. En este enfoque, los modelos especializados no sustituyen al agente, sino que lo alimentan con señales estructuradas que permiten generar respuestas más informadas, empáticas y orientadas a la gestión del problema. Esta separación entre análisis y generación ha resultado especialmente útil para mantener un diseño modular y extensible.

Este proyecto debe entenderse como un punto de partida más que como un sistema cerrado. Existen numerosas líneas de mejora, como la incorporación de anotaciones manuales para permitir evaluaciones cuantitativas más rigurosas, el uso de embeddings de frases directamente en el modelado temático, la inclusión de información temporal y geográfica para una priorización más precisa, o la integración con sistemas reales de tramitación municipal. Asimismo, el componente visual se ha explorado únicamente como prueba de concepto, pero sugiere el potencial de enfoques multimodales más completos en futuros desarrollos.

5. Reproducibilidad

Todos los experimentos, modelos entrenados y demostraciones descritos en este trabajo pueden reproducirse a partir del código entregado como anexo digital, que incluye:

- notebooks para la clasificación temática, el análisis de sentimiento y la extensión multimodal,
- módulos de preprocesamiento, inferencia y recuperación semántica,
- artefactos de los modelos entrenados (vectorizadores, modelos NMF y LDA y mapeos de tópicos),
- y la aplicación de demostración del agente conversacional.

Por motivos de licencia y tamaño, el conjunto de datos original no se incluye en la entrega. El archivo `README.md` proporciona el enlace al portal oficial de datos abiertos del Ayuntamiento de Madrid y describe cómo descargar el dataset y ubicarlo correctamente en la estructura del proyecto para reproducir los experimentos. Asimismo, el fichero `requirements.txt` especifica las dependencias necesarias y el `README.md` detalla el orden recomendado de ejecución de los distintos módulos.

Referencias

Ayuntamiento de Madrid. (2024). Propuestas ciudadanas. Portal de Datos Abiertos del Ayuntamiento de Madrid [Accedido para la elaboración del conjunto de datos del proyecto].

Barde, B. V., & Bainwad, A. M. (2017). An overview of topic modeling methods and tools. *2017 international conference on intelligent computing and control systems (ICICCS)*, 745-750.

Blei, D. M., Ng, A. Y., & Jordan, M. I. (2003). Latent dirichlet allocation. *Journal of machine Learning research*, *3*(Jan), 993-1022.

Bonilla, F. D. S., Oconitrillo, N. V., Castro, J. D. G., Durán, A., & Chavarría, A. P. J. (2021). BETO Emotion Analysis of Facebook Users Reacting to Major Media Outlets in Costa Rica. *2021 Third International Conference on Transdisciplinary AI (TransAI)*, 107-111.

Church, K. W. (2017). Word2Vec. *Natural Language Engineering*, *23*(1), 155-162.

De Arriba, A., Oriol, M., & Franch, X. (2021). Applying Sentiment Analysis on Spanish Tweets Using BETO. *IberLEF@ SEPLN*, 86-93.

Di Gennaro, G., Buonanno, A., & Palmieri, F. A. (2021). Considerations about learning Word2Vec. *The Journal of Supercomputing*, *77*(11), 12320-12335.

Fernández, D. (2025). Apuntes de la asignatura Procesamiento del Lenguaje Natural [Material docente no publicado, Universidad UTAMED].

Jelodar, H., Wang, Y., Yuan, C., Feng, X., Jiang, X., Li, Y., & Zhao, L. (2019). Latent Dirichlet allocation (LDA) and topic modeling: models, applications, a survey. *Multimedia tools and applications*, *78*(11), 15169-15211.

Johnson, S. J., Murty, M. R., & Navakanth, I. (2024). A detailed review on word embedding techniques with emphasis on word2vec. *Multimedia Tools and Applications*, *83*(13), 37979-38007.

Li, J., Li, D., Xiong, C., & Hoi, S. (2022). Blip: Bootstrapping language-image pre-training for unified vision-language understanding and generation. *International conference on machine learning*, 12888-12900.

Liu, C.-z., Sheng, Y.-x., Wei, Z.-q., & Yang, Y.-Q. (2018). Research of text classification based on improved TF-IDF algorithm. *2018 IEEE international conference of intelligent robotic and control engineering (IRCE)*, 218-222.

Qader, W. A., Ameen, M. M., & Ahmed, B. I. (2019). An overview of bag of words; importance, implementation, applications, and challenges. *2019 international engineering conference (IEC)*, 200-204.

Surya, J., & Aminuddin, F. H. (2024). *Pemrograman MYSQL Database With Streamlit Python*. PT. Sonpedia Publishing Indonesia.

Xu, Z., Chen, L., Dai, Y., & Chen, G. (2017). A dynamic topic model and matrix factorization-based travel recommendation method exploiting ubiquitous data. *IEEE Transactions on Multimedia*, *19*(8), 1933-1945.

Zhou, W., Ye, Z., Yang, Y., Wang, S., Huang, H., Wang, R., & Yang, D. (2023). Transferring Pre-Trained Large Language-Image Model for Medical Image Captioning. *CLEF (Working Notes)*, 1776-1784.